面向不平衡数据集的汽车零部件质量预测

李敏波[1,2] 董伟伟[1]
1.复旦大学软件学院，上海，200433
2.复旦大学上海市数据科学重点实验室，上海，200433

摘要：针对汽车零部件质检数据存在合格品与不合格品数量不平衡的问题，提出了基于密度聚类与多工序制造特征的 MCDC-MF-SMOTE 质检数据过采样方法。先对少数类（不合格）与多数类（合格）样本分别进行密度聚类，再对多工序制造数据和类簇样本分布进行过采样权重计算；根据设定的过采样比和类簇权重，在少数类簇中进行过采样数据生成。使用 MCDC-MF-SMOTE 过采样方法生成汽车零部件质检的平衡数据集，并采用随机森林排序制造特征的重要性，对分类模型 LightGBM、XGBoost、SVM 和 MNB 进行 Stacking 集成来预测不合格品。与随机抽检相比，该方法对不合格产品的检出率提高了约 63%。

关键词：数据不平衡；质量预测；密度聚类；集成学习
中图分类号：TP182
DOI：10.3969/j.issn.1004-132X.2022.01.010 **开放科学（资源服务）标识码（OSID）**：

Quality Prediction of Automotive Parts for Imbalanced Datasets

LI Minbo[1,2] DONG Weiwei[1]
1.Software School, Fudan University, Shanghai, 200433
2.Shanghai Key Laboratory of Data Science, Fudan University, Shanghai, 200433

Abstract: In response to the problems of imbalance between quantity of qualified and unqualified automotive parts for the product inspection datasets, a MCDC-MF-SMOTE oversampling method of quality inspection data was proposed based on density clustering and multi-process manufacturing features. Firstly, density clustering was carried out for the minority(unqualified) and the majority(qualified) samples respectively, and then oversampling weight was calculated by multi-process manufacturing data and cluster sample distribution. Data were generated in a few clusters according to oversampling ratio and cluster weights. The MCDC-MF-SMOTE method was used to generate a balanced quality dataset of automotive parts. Random Forest was used to rank feature importance to reduce feature dimension. LightGBM, XGBoost, SVM, and MNB models for Stacking were integration to predict unqualified products. After experiments, this method has higher stability and quality prediction performance. Compared with random sampling, the detection rate of unqualified products is increased by approximately 63%.

Key words: data imbalance; quality prediction; density clustering; integrated learning

0 引言

随着“工业互联网”和“工业 4.0”等概念的提出，工业领域的信息化、智能化发展愈发受重视，越来越多的制造企业建立了生产过程数据采集系统与制造执行系统，积累了大量工业数据。这些工业数据分布在不同的孤立信息系统中，存在实时性高、复杂多样和类别不平衡等问题。现有的产品质量预测方法往往使用单一系统的数据集，且只面向于特定的制造领域，具有较大的局限性，难以满足制造企业实时质量抽检的预测需求。常见的产品质量预测研究往往局限于质量预警和预测性维护等方面，这些研究难以用于实际的工业场景[1-3]。汽车零部件制造存在大批量生产、小样本抽样检测的特点，例如轮胎动平衡为全检，而部分轮胎企业的均匀性检测为抽检，柴油和汽油发动机的部分试车工况测试为抽检。大批量生产的汽车零部件合格率一般在 95%以上，而小样本抽检的随机性会造成不合格产品检出率较低，增加产品售后返修及物流成本。

制造数据集中，合格与不合格的产品数量差距悬殊，存在严重的类别不平衡问题。现有的类别不平衡解决方法分为预处理方法、代价敏感方法、算法中心方法和混合方法[4-6]，其中，预处理方

收稿日期：2020-06-12
基金项目：国家重点研发计划（2018YFB1703104）；国家自然科学基金（61671157）

法包括特征选择方法、过采样方法、欠采样方法和混合采样方法。一般来说，过采样方法具有更高的性能，文献[7-10]分别利用 Lowner John 椭球理论、元启发式方法、构造覆盖算法的无参数数据清洗方法和自组织图方法对少数类样本进行过采样，极大提高了对多领域不平衡数据集的分类性能。然而在面对信息繁杂且蕴含众多领域业务特征的制造数据集时，现有方法仍有进一步的改善空间，由此本文提出了基于密度聚类与多工序制造特征的质检数据过采样方法。

对制造数据不同层次的类别属性预测包括故障预测和产品质量预测。产品质量预测在本质上是一个二分类问题，即将生产制造数据集训练出的有效分类模型用于产品的良率预测与抽检产品的选择。文献[1-3]利用支持向量机(SVM)、随机森林、决策树和深度学习等方法，对车辆气压系统和机床进行故障检测及预测的研究。朱海平等[11]应用遗传算法改良 EWMA 控制图，量化产品质量不合格的概率并优化相关参数。吕旭泽[12]针对发动机多工序装配的回转力矩检测误差波动大、影响装配质量的问题，构建了基于粒子群参数优化与最小二乘支持向量机的发动机多工序装配预测曲轴回转力矩模型。赵双凤[13]提出了结合 BP 神经网络和灰色模型的质量预测模型来预测轴类零件车削加工测量值。于文靖[14]研究了汽轮机模锻叶片加工质量预测，建立了基于粒子群优化(PSO)算法与 SVM 算法并结合统计过程控制(SPC)的多工序质量预测控制系统。冯尔磊[15]针对表面安装工艺中锡膏印刷环节，提出一种基于层次聚类和 PSO 优化的 RBF 神经网络的锡膏印刷体积预测模型。本文提出了将 LightGBM、XGBoost、SVM 和 MNB 模型进行 Stacking 集成的汽车关重件质量抽检预测方法。

1　MCDC-MF-SMOTE 过采样方法

大数据下的质量预测控制研究主要集中于质量管控过程框架、数据挖掘方法、在线质量诊断与监控、在线质量预测等领域[16]。常用质量预测方法主要有灰色预测模型、人工神经网络预测模型、支持向量回归(support vector regression，SVR)预测模型、模糊预测控制模型以及上述算法的整合模型。针对产品质量预测及其关键的类别不平衡问题，本文研究基于密度聚类与制造业务特征(multi class density cluster-manufacture feature-synthetic minority over-sampling technique，MCDC-MF-SMOTE)的过采样方法。

SMOTE(synthetic minority over-sampling technique)-Regular 算法采用 K 最近邻(K-nearest neighbor，KNN)分类算法模拟生成新样本来解决数据集分类的类别不平衡问题，但面对高维且分布复杂的数据集时，该算法的分类模型准确率不高，因此出现了 SMOTE-borderline、k-means-SMOTE、Random-SMOTE 和 CURE-SMOTE 等改良方法，这些方法考虑了不同类别的数据分布情况和少数类噪声问题，利用分布边界、聚类和生成权重调整等方法解决了 SMOTE-Regular 的诸多问题[17]。制造数据集不仅具有高维且复杂的分布特征，不同类别的样本数据还有重叠，直接使用上述 SMOTE 改进方法，难以有效学习到数据中所有质量影响因素的信息，使得产品质量预测模型难以用到实际的生产场景。

图 1 所示为基于密度聚类和制造业务特征的数据过采样方法框架。首先对制造数据集进行适当的预处理(包括缺失值处理、错误数据修正、数据标准化等操作)，形成高质量且适合模型训练的数据集。笔者将数据集按产品质量类别标签分成两个数据集：一个包含所有不合格产品(少数类)样本，另一个包含所有合格产品(多数类)样本。接着对这两个数据集进行密度聚类，形成对应的类簇集合。利用多工序制造特征计算少数类簇的数据生成权重，然后利用数据生成权重对少数类簇进行数据生成，并对利用多数类簇判断生成的数据是否合理。最终按照分类模型需要重组数据，形成平衡后的数据集。

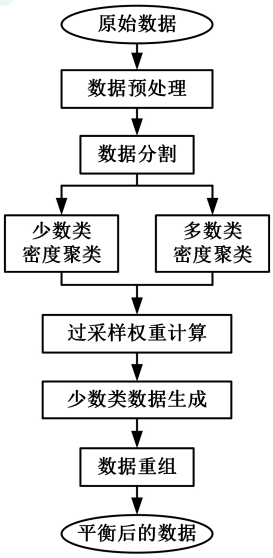


图 1　MCDC-MF-SMOTE 过采样方法架构

Fig.1　Architecture of MCDC-MF-SMOTE oversampling method

1.1　密度聚类方法分析与选择

密度聚类方法可以根据数据的分布密集程度

考察数据间的相似性，相比于 k-means 等方法，不需要指定类簇数量就能发现任意形状的类簇，且对噪声数据有更高的鲁棒性。

为分析不同聚类方法的适应性，利用 scikit-learn 软件的 datasets 工具包合成 6 种不同分布的数据集。选择 6 种基于不同理论的聚类方法对合成的数据集进行聚类实验，图 2 中，从左向右依次为 K-means、Agglomerative Clustering、Birch、MeanShift、DBSCAN、OPTICS 6 种聚类方法对合成的数据集进行聚类实验的结果，可以看出，k-means、Birch 和 MeanShift 算法会拆分密度分布相同的类簇，如第六行的数据集 6，2 个弧形分布数据被错误地截断为不同类簇（第六行的第 1、3、4 列）。Agglomerative Clustering 算法易将数据集 4、5 中不同的类簇识别为同一类簇。OPTICS 算法会将一些密度分布松散的类簇识别为噪声，且多次参数调整后的效果仍不理想。DBSCAN 算法在每一种数据集下都有最好的分类表现，能有效区分不同形状的类簇，且会引入更少的噪声数据。所以最终选择 DBSCAN 算法对制造质量相关数据集进行聚类，并在不同类簇中生成少数类数据。

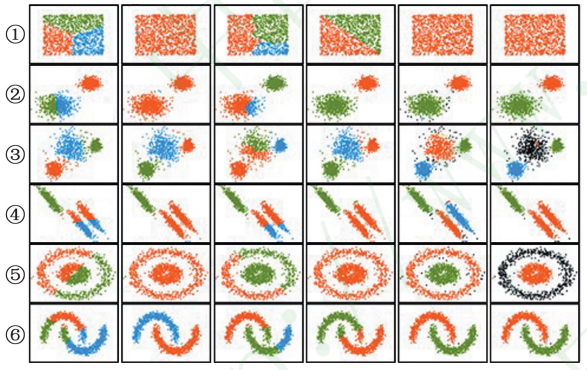


图 2　聚类实验结果

Fig.2　Experimental results of clustering

1.2　基于多工序制造特征的过采样权重定义

产品制造数据集包含人员、设备、物料和操作等影响产品质量的制造特征，这些特征在一段时间内通常会保持相似的状态。产品质量问题往往是由某一工序环节的制造偏差造成的，整体来看，不合格产品会在某一时间段内重复出现。图 3 为轮胎动平衡检验的产品质量趋势图，横坐标为动平衡检验时刻，纵坐标表示产品质量，1 表示合格产品，0 表示不合格产品。红框标注了聚集出现较多不合格品的情况，可利用滑动窗口的方法判断一定时间内生产的不合格产品数量是否超过阈值。若超过阈值，则滑动窗口内的数据包含更多的低质量产品的信息，应该受到更多的关注，过采样时，可将此类数据赋予更大的过采样权重。

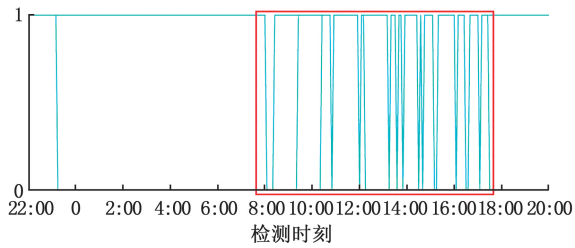


图 3　轮胎动平衡质量趋势

Fig.3　Quality trend of tire dynamic balance

利用上述分析的制造数据集特征和数据的密度分布情况，设计对少数类簇进行数据生成时的过采样权重。首先定义样本 $D=\{(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)\}$，其中，$n$ 为样本数量，x_i 表示样本 i，$y_i\in\{0,1\}$，其中，1 表示质量合格，0 表示不合格。定义滑动窗口 $L_{s\text{-}e}$ 为固定时间长度，s、e 分别为滑动窗口的开始时间与结束时间；$\min A$ 为低质量产品的最小出现次数，$N_0(L_{s\text{-}e})$ 为滑动窗口内出现的低质量产品数量；dep_{len} 为滑动窗口移动步长。$N_0(L_{s\text{-}e})>\min A$ 时，窗口为有效滑动窗口，属于某个有效滑动窗口的样本称为有效滑动样本；按照指定步长移动滑动窗口，最终得出有效滑动窗口集合 $T=\{L_{s,1\text{-}e,1},L_{s,2\text{-}e,2},\cdots,L_{s,l\text{-}e,l}\}$。由于样本具有时间属性，因此可以判断出每个样本是否归为有效滑动样本。

接着利用基于混合类型距离的 DBSCAN 算法对原始样本进行密度聚类，形成少数类簇 $C_a=\{c_{a,1},c_{a,2},\cdots,c_{a,v}\}$ 和多数类簇 $C_b=\{c_{b,1},c_{b,2},\cdots,c_{b,w}\}$，其中，$v$、$w$ 分别为少数类簇和多数类簇的数量。$N(c_{a,v})$ 为 $c_{a,v}$ 类簇的样本数量，$D(c_{a,v})$ 为 $c_{a,v}$ 类簇空间所包含的多数类样本数量，$S(c_{a,v})$ 为 $c_{a,v}$ 类簇含有的有效滑动样本的数量。类簇包含的有效滑动样本越多，该类簇的数据权重越大。最终定义的类簇过采样权重为

$$G_{\text{W}}(c_{a,v})=\beta_1\frac{N(c_{a,v})}{\sum_{i=1}^{v}N(c_{a,i})}\beta_2\frac{N(c_{a,v})}{D(c_{a,v})}\beta_3\frac{S(c_{a,v})}{N(c_{a,v})}\tag{1}$$

其中，$\sum_{i=1}^{v}N(c_{a,i})$ 为所有少数类簇样本数量；β_1、β_2、β_3 为权重，则式(1) 可化简为

$$G_{\text{W}}(c_{a,v})=\beta_1\beta_2\beta_3\frac{N(c_{a,v})}{\sum_{i=1}^{v}N(c_{a,i})}\frac{S(c_{a,v})}{D(c_{a,v})}\tag{2}$$

1.3　过采样算法流程

基于密度聚类和过采样权重定义方法，介绍基于 MCDC-MF-SMOTE 的整体流程。定义 D_{original} 为原始样本；过采样率 η_{OR} 为数据生成后的少数类样本数量与原始多数类样本数量的比

值；J 为生成数据无效时所进行的重试次数，防止出现死循环；WDMC 表示不同类簇的过采样权重计算过程算法；D_{balanced} 为经过该算法处理后的样本。使用基于混合类型距离 D_{mix} 的密度聚类算法 $DBSCAN_{D_{\text{mix}}}$ 对原始样本进行密度聚类，具体算法如下：

输入：数据集 $D_{\text{original}} \leftarrow \{(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)\}, y_i=\{0,1\}$；

$DBSCAN_{D_{\text{mix}}}$：密度聚类算法参数：半径 $\in$，最小数量 $MinPts$；

输出：$D_{\text{balanced}} \leftarrow \{(x_1,y_1),(x_2,y_2),\cdots,(x_z,y_z)\}, y_z=\{0,1\}$.

方法：

1./*（1).初始数据集预处理 */

2.$D_{\text{processed}} \leftarrow P(D_{\text{original}})$；

3./*（2).类分割与每个少数类簇的权重定义 */

4.初始化 $GenWht \leftarrow \varnothing, D_{\min} \leftarrow \varnothing, D_{\text{maj}} \leftarrow \varnothing, G_q \leftarrow 0, i \leftarrow 0, C_a \leftarrow \varnothing, C_b \leftarrow \varnothing, D_{\text{noise}} \leftarrow \varnothing$；

$GenWht, D_{\min}, D_{\text{maj}}, C_a, C_b \leftarrow WDMC(D_{\text{processed}}, \varepsilon minPts, dep_{\text{len}}, L_{s\text{-}e}, minA, \beta_1, \beta_2, \beta_3)$；

5.$D_{\text{noise}} \leftarrow D_{\text{processed}}(D_{\min}, D_{\text{maj}})$；

/*（3).根据少数类簇的权重值生成数据，通过多数类簇去除无效数据 */

6.initialize $G_q \leftarrow 0, W_{\text{all}} \leftarrow 0, G_c \leftarrow \varnothing$.

7.$G_q \leftarrow OR \cdot N(D_{\text{maj}}) - \sum_{i=1}^{v} N(c_{a,v}) - D_{\text{noise}}, y_n = 0$；

8.$W_{\text{all}} \leftarrow \sum_{i=1}^{v} GWeight(c_{a,i})$；

9.**for** $i \leftarrow 1 : v$ **do**

10.$G_{c,i} \leftarrow G_q \cdot \dfrac{GWeight(c_{a,i})}{W_{\text{all}}}, G_c \leftarrow G_c \cup G_{c,i}$；

11.**end for**

12.**while** $G_q > 0$ **do**

13.　$i \leftarrow i+1$, $i \leftarrow i\%v$；

14.　**if** $G_{c,i} > 0$ **do**

15.　　randomly select $(x_{\text{old},0}, x_{\text{old},1}) \in C_{a,i}$；

16.　　initialize $j \leftarrow 0$；

17.　　**while** $j < jump$ **do**

18.　$j \leftarrow j+1, x_{\text{new}} \leftarrow x_{\text{old},0} + U_{\text{dynamic}}(0,1) \cdot (x_{\text{old},1} - x_{\text{old},0})$；

19.　　/* judge data valid by C_b. */

20.　　**if** x_{new} is valid **then**

21.　$G_q \leftarrow G_q - 1$,

22.　$D_{\min_\text{balanced}} \leftarrow D_{\min_\text{balanced}} \cup x_{\text{new}}$；

23.　**break**；

24.　　**end if**

25.　**end while**

26.　**end if**

27.**end while**

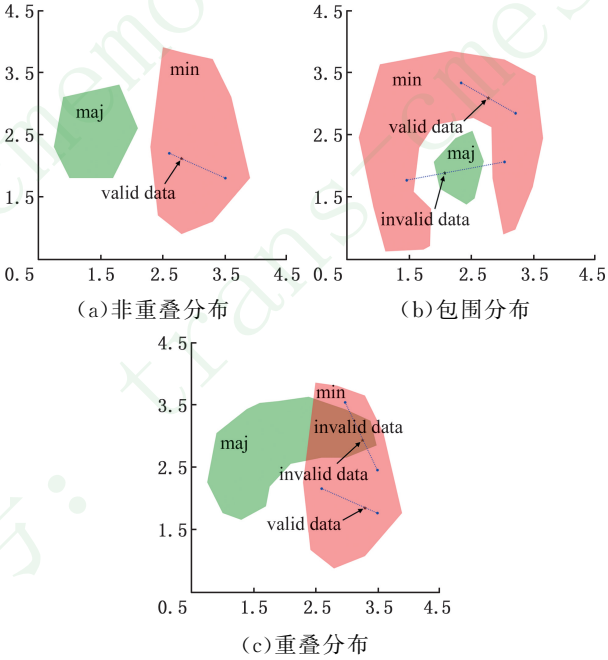
/*（4).数据集重构 */

28.initialize $D_{\text{balanced}} \leftarrow \varnothing$；

29.$D_{\text{balanced}} \leftarrow D_{\text{maj}} \cup D_{\min_\text{balanced}} \cup D_{\text{noise}}$；

重点为步骤(3)，即根据少数类簇权重生成数据，根据多数类簇判断生成数据的有效性。数据无效时，重新生成数据并判断其有效性。

图 4 所示为不同的少数类簇与多数类簇的分布，用 min 标识的红色区域表示少数类簇，用 maj 标识的绿色区域表示多数类簇，横纵坐标都为数据的 x、y 值坐标，它们共有 3 种分布方式：非重叠分布、包围分布、重叠分布。对于非重叠分布，从少数类簇区域中随机选择 2 个样本点，取两点连接线之间随机一点为新生成数据。对于包围分布，当生成数据落在多数类族区域时，重新选择 2 个样本点，并用迭代折半的方法在距离样本点更近的位置生成数据。对于重叠分布，首先将重叠区域设置为 invalid area，然后判断独立少数类簇区域是非重叠分布还是包围分布，并按照响应方法进行数据生成。



(a)非重叠分布　(b)包围分布

(c)重叠分布

图 4　少数类簇与多数类簇分布

Fig.4　Distribution of minority and majority clusters

2　Stacking 集成的产品质量预测方法

MCDC-MF-SMOTE 方法能产生有效的平衡数据集，提高多个分类算法的泛化性能，并使 LightGBM(light gradient boosting machine)模型获得最好的产品质量预测结果。考虑到汽车零部件生产过程和相关制造数据集的复杂性，单一分类算法难以适应各种的制造场景。例如 Expo 和 Higgs 数据集上的二分类问题，极限梯度提升(extreme gradient boosting，XGBoost)模型的分

类性能强于 LightGBM 模型。本文提出基于 Stacking 集成的 LXSMS(LightGBM- XGBoost-SVM-MNB Stacking)方法,如图 5 所示,具体步骤如下:

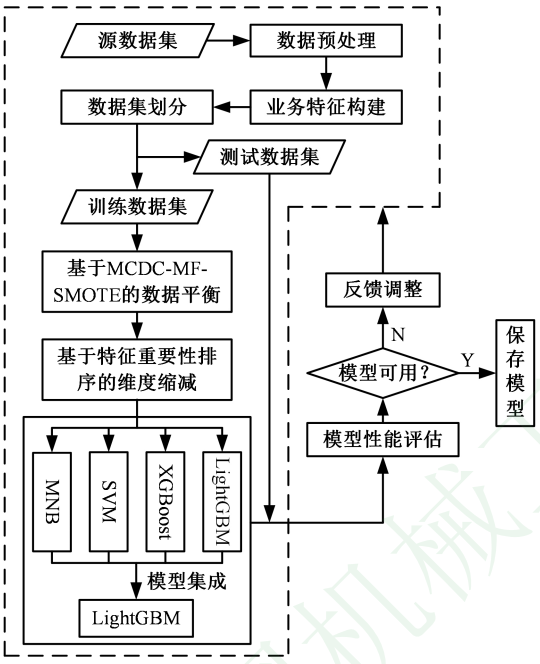


图 5 LXSMS 方法整体流程

Fig.5 Overall flow of LXSMS method

(1)数据预处理。该步骤初步梳理制造数据集,需要考虑数据的类型,如数值型、时间型和文本型的属性以及属性背后的实际质量相关性。

(2)多工序制造特征构建。经过对制造数据集的预处理和对多工序制造质量相关影响因素的了解,利用多个已有特征构建新的组合特征,这些组合特征往往在最终模型中起决定作用。

(3)数据集划分。为保证训练出的模型符合真实的产品质量预测场景,需在数据平衡及降维之前进行数据集划分。首先按照业务发生时间对数据进行先后排序,之后将前 80%的数据作为训练数据集,将余下的数据作为测试数据集。

(4)MCDC-MF-SMOTE 算法的数据平衡。制造数据集存在类别不平衡问题,严重影响分类方法的性能,MCDC-MF-SMOTE 算法充分考虑了数据分布和制造业务特征,能生成高质量的平衡数据集,有效解决该问题。

(5)基于特征重要性的维度缩减。数据集特征过多时,部分特征往往是质量影响度很小的冗余特征,且模型需要耗费更长的时间去训练和调整参数,因此使用随机森林对所有特征进行重要性排序并剔除部分排名靠后的特征。该方法能在保证特征蕴含足够知识的前提下,缩短模型训练时间,提高模型分类性能。

(6)Stacking 集成。第一层基分类器主要采用分类模型 LightGBM、XGBoost、SVM(支持向量机)和 MNB(多项式先验分布朴素贝叶斯),每个模型都采用五折交叉验证的方法训练并输出预测结果到第二层元分类器层。需要注意的是,五折交叉采样需采用分层抽样的方式,以保证不同模型使用同样分布的数据。LightGBM 模型训练极快且比逻辑回归模型的分类性能高,所以选择 LightGBM 模型作为元分类器,利用第一层得到的预测数据进行训练并得出最终的产品质量预测结果。

(7)模型评估与参数调整。评估模型需综合考虑模型的训练时间和受试者工作特征曲线(receiver operating characteristic curve,ROC)、ROC 曲线下的面积(area under curve, AUC)等指标,并利用网格搜索方法调整参数。模型达到要求时,保存模型为 PMML(预测模型标记语言)格式,并将其应用到实际生产业务。

3 实验设计与结果分析

本文实验数据源于青岛双星股份公司 MES 数据库,轮胎生产均匀性检验阶段采取的是 20%随机抽检的方式。利用均匀性检验之前的所有数据训练模型来预测均匀性检验阶段的产品质量,辅助进行均匀性抽检工作,降低不合格轮胎的漏检率。表 1 所示为相关数据的说明。经过数据预处理,最终使用 2019 年 1 月到 4 月的 269 835 条轮胎生产制造数据,其中,合格轮胎 254 370 条、不合格轮胎 15 465 条,合格率为 94.27%,不平衡比为 15.4。

表 1 轮胎制造数据说明

Tab.1 Description of tire manufacturing data

数据表	属性数	记录数	说明
半成品外检表	30	282 383	帘布、胎面等轮胎组件检验结果
轮胎成形表	19	2 258 077	轮胎成形过程数据
轮胎硫化表	38	2 158 612	轮胎硫化过程数据
X 光检验表	36	2 109 121	轮胎 X 光检验结果
外观检验表	25	2 047 533	轮胎外观检验结果
动平衡检验表	70	2 024 131	轮胎动平衡检验结果
均匀性检验表	59	398 258	轮胎均匀性检验结果

准确率(Precision)和召回率(Recall)仅关注单一维度的模型性能,难以综合评估不平衡数据下的模型对不同类别的泛化能力。AUC、ROC 等指标有一定偏向性,使用准确召回率曲线面积(precision-recall curve,AUCPRC)能在一定程度上修正 AUC、ROC 的偏向性,它是以准确率 η_p 为 Y 轴、召回率 η_{rec} 为 X 轴所形成的曲线下的面积。针对批量生产的汽车零部件工序抽样检验的

质量预测希望预测更多的不合格产品，召回率 η_{rec} 允许值更小，针对此类场景，选择 AUCPRC 来综合评价产品质量预测模型更有意义。同时结合抽检比例的业务特征，最终选择预测为合格样本数量与总样本数量的准确率 η_P、召回率 η_{rec}、综合评价指标 F1-Score(S_{F1})和 A_{AUCPRC} 作为模型的评价指标。

3.1　不同过采样方法分类性能对比实验

本次实验主要使用算法 XGBoost、LightGBM 和 SVM(支持向量机)，其中，GBoost 和 LightGBM 均以 binary:logistic 为目标函数(objective)，已定义评价函数(eval_metric)为 AUCPRC，提升类型(booster_type)为梯度提升树(gradient boosting decision tree，GBDT)算法，学习率(learning_rate)、树深(max_depth)和树的个数(n_estimators)参数采用网格搜索选取最优值，其他参数取默认值。SVM 使用 sklearn.svm.SVC 方法，kernel 设置为 rfb，class_weight 设置为 balanced，利用网格搜索调整惩罚系数 C，其他参数均取默认值。过采样方法中，Original 表示不进行过采样，其他过采样方法均使用 python 算法库对原始数据进行处理，MCDC-MF-SMOTE 算法设置 $\varepsilon=10$，$minPts=3$，$\eta_{OR}=1$，$\beta_1=\beta_2=\beta_3=1$，$jump=3$，$L_{s\text{-}e}=600$，$minA=3$，$dep_{len}=10$。最终的实验结果取五折交叉验证的平均值。如表 2 所示，可以看出，MCDC-MF-SMOTE 方法取得最大的 S_{F1}、η_{rec} 和 A_{AUCPRC} 且 η_P 均小于 0.2，符合轮胎均匀性检测按 20%比例随机抽检的业务要求。相比除了 Original 的其他过采样方法，MCDC-MF-SMOTE 的 A_{AUCPRC} 增大了 5%～49%。此外，LightGBM 配合 MCDC-MF-SMOTE 过采样方法取得了最大的 η_{rec}、S_{F1} 和 A AUCPRC值。

3.2　不同过采样率分类性能对比实验

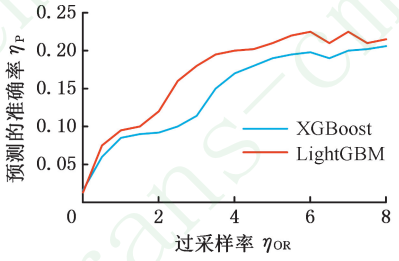
用过采样方法处理不平衡数据集时，过采样率 η_{OR} 设为 1 表示少数类样本采样数量与多数类样本数量相同。不同的过采样率会影响分类模型的最终性能，应用轮胎制造数据集探讨 MCDC-MF-SMOTE 方法的不同过采样率对分类性能的影响。LightGBM 和 XGBoost 使用默认参数设置，MCDC-MF-SMOTE 仅更改 η_{OR} 的参数设置，采用五折交叉验证，最终结果取平均值。

实验结果如图 6 所示，横轴表示过采样率 η_{OR}，$\eta_{OR}=0$ 表示不进行过采样。纵轴分别表示 η_P、η_{rec} 和 A_{AUCPRC} 的性能指标值。可以看出，η_{OR} 较小时，XGBoost 有更好的性能。随着 η_{OR} 的增大，XGBoost 和 LightGBM 整体性能都在提升，

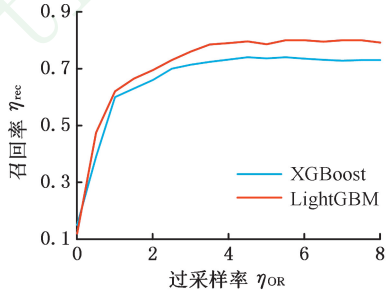
表 2　不同过采样方法实验结果

Tab.2　Experimental results of different oversampling methods

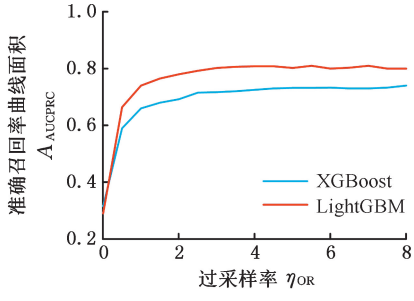
分类方法	过采样方法	η_P	η_{rec}	S_{F1}	A_{AUCPRC}
XGBoost	Original	0.016	0.154	0.243	0.317
	Regular-SMOTE	0.102	0.425	0.479	0.502
	Borderline-SMOTE1	0.078	0.592	0.596	0.629
	Random-SMOTE	0.084	0.569	0.584	0.613
	k-means-SMOTE	0.079	0.574	0.595	0.615
	ADASYN	0.081	0.571	0.577	0.607
	MCDC-MF-SMOTE	0.073	0.603	0.624	0.662
LightGBM	Original	0.013	0.127	0.218	0.284
	Regular-SMOTE	0.137	0.374	0.491	0.497
	Borderline-SMOTE1	0.092	0.593	0.651	0.707
	Random-SMOTE	0.098	0.572	0.602	0.669
	k-means-SMOTE	0.103	0.584	0.649	0.691
	ADASYN	0.116	0.581	0.643	0.685
	MCDC-MF-SMOTE	0.095	0.626	0.697	0.742
SVM	Original	0.029	0.095	0.138	0.193
	Regular-SMOTE	0.159	0.314	0.396	0.409
	Borderline-SMOTE1	0.103	0.552	0.554	0.586
	Random-SMOTE	0.131	0.533	0.529	0.552
	k-means-SMOTE	0.144	0.549	0.548	0.574
	ADASYN	0.115	0.537	0.537	0.569
	MCDC-MF-SMOTE	0.106	0.583	0.571	0.608



(a)准确率



(b)召回率



(c) 准确召回率曲线面积

图 6　不同过采样率实验结果对比

Fig.6　Comparison of experimental results with different oversampling rates

但 LightGBM 整体性能的提升速度更高。XGBoost 在 η_{OR} 超过 4.5、LightGBM 在 η_{OR} 超过 3 后，η_{rec} 和 A_{AUCPRC} 都趋于稳定，且满足 η_P 小于0.2。特别是 LightGBM 的 AUCPRC 指标已经到达了 0.803，比 $\eta_{OR}=1$ 时的性能提升了约 8%。随着 η_{OR} 的进一步增大，XGBoost 和 LightGBM 的性能趋于稳定，但是 η_P 却在逐步增大，超过了 0.2 的抽检阈值，不满足辅助质量抽检的业务需要。整体来看，LightGBM 有着更好的性能，且模型训练耗时约为 XGBoost 的1/10。

3.3 不同分类方法的产品质量预测性能对比实验

本实验主要对比算法 LXSMS、LightGBM、XGBoost、SVM、随机森林和 MNB。选取轮胎制造数据集的 80%数据为训练数据，余下 20%数据作为测试数据。每个算法都采取 MCDC-MF-SMOTE 方法平衡数据，并设置 η_{OR} 为其最优性能时的过采样率，设置 $\varepsilon=10$，$\min Pts=3$，$\eta_{OR}=1$，$\beta_1=\beta_2=\beta_3=1$，$jump=3$，$L_{s\text{-}e}=600$，$\min A=3$，$dep_{len}=10$。

LXSMS 在集成模型的第一层中使用了五折交叉验证，所以除了 LXSMS，其他方法的最终实验结果取五折交叉验证的平均值。

由表 3 的实验结果可以看出，相比单一模型中表现最好的 LightGBM，LXSMS 的 η_{rec} 和 A_{AUCPRC} 分别提高了约 6%和 3%；相比表现最差的 MNB，LXSMS 的 η_{rec} 和 A_{AUCPRC} 分别提高了约 36%和 31%。这表明基于 Stacking 集成的 LSXMS 方法有着更高的产品质量预测性能。

表 3 不同分类算法的产品质量预测性能

Tab.3 Product quality prediction performance for different classification methods

算法	η_{rec}	A_{AUCPRC}
LXSMS	0.836	0.827
LightGBM	0.789	0.803
XGBoost	0.749	0.731
SVM	0.629	0.651
随机森林	0.703	0.718
MNB	0.614	0.632

3.4 不同分类方法产品质量预测稳定性实验

产品制造是一个持续的过程，会源源不断产生新的数据，随着时间的推移，产品质量预测模型的预测能力往往会持续下降。为了分析不同模型的稳定性即模型对新数据的预测能力，本次实验将 269 835 条轮胎制造数据按照时间进行排序，取前 30%的数据为训练数据，后 70%的数据为测试数据，测试算法 LXSMS、LightGBM、XGBoost、SVM、随机森林和 MNB 的稳定性。

由图 7 可以看出，在每一种数据划分下，LSXMS 的 η_{rec} 都最大且下降缓慢，有较高的稳定性。随着轮胎数量的增长，模型的预测性能持续降低，不适应产品抽检的业务要求，所以需要在适当时刻，采取增量更新的方式训练新的模型。

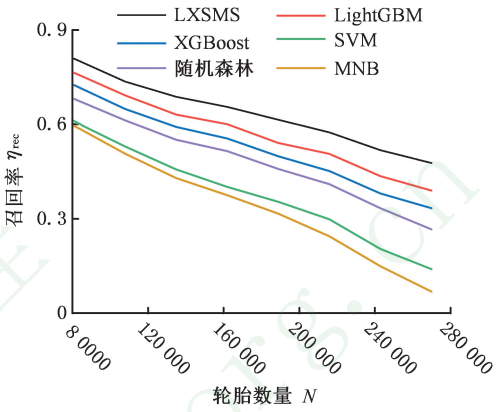


图 7 不同分类方法产品质量预测稳定性

Fig.7 Stability of product quality prediction by different classification methods

3.5 随机抽检与模型抽检性能对比实验

为进一步验证 LXSMS 方法在真实产品制造场景中的适应性，将已标记检验质量的 269 835 条轮胎生产数据，按照时间节点划分，将 2019 年 3 月之前的 210 808 条数据作为模型训练数据，将 2019 年 4 月的 59 027 条数据作为轮胎检验数据。对于轮胎检验数据，设置随机抽检和模型抽检对照实验，并分别进行两种检验处理：随机抽检从轮胎检验数据中重复 10 次随机取出 20%的轮胎并标记为抽检轮胎，结果取平均值（轮胎数量如果为小数则四舍五入为整数）；模型抽检使用 LXSMS 方法从训练数据中构建出初始质量预测模型，并利用该模型模拟实时预测过程，将预测不合格的轮胎标记为抽检轮胎。最后使用已知的轮胎质量结果来判断两种抽检方式的性能，如表 4 所示。

表 4 随机抽检与模型抽检的性能

Tab.4 Performance of random sampling and model sampling

分组	待抽检轮胎数量	抽检轮胎数量	抽检不合格的轮胎数量	真正不合格的轮胎数量	不合格轮胎检出率
随机抽检	59 027	11 805	648	2946	0.22
模型抽检	59 027	10 098	2504	2946	0.85

从实验结果可以看出，模型抽检在抽检了 17.1%的轮胎后，达到了 85%的不合格轮胎检出率，而随机抽检只检出 22%的不合格轮胎。由此可见，本文提出的 LXSMS 方法能显著提高不合

格轮胎检出率，在更低检验成本的情况下，检测出更多的不合格轮胎，帮助企业提升经济效益。

3.6　深度学习对不平衡制造数据集的适用性分析

深度学习常用于图像、音频和文本等领域。对于汽车零部件质量抽检预测及其相关的多工序制造数据集来说，由于质量不合格品的负小样本数据较少，因此深度学习难以取得良好的应用效果。

从数据量来说，制造数据集中的有效数据往往是较小规模的样本，相比动辄过千万的图像与文本数据，深度学习算法难以训练出高泛化能力的模型。基于集成方法的 LSXMS 能从小样本数据集中充分学习到数据特征，且支持加入业务规则进行精细化调整，更加适合中小规模数据集的制造数据分析。

从效率来说，深度学习需要耗费更多的计算成本和更长的训练时间，且往往需要高性能 GPU 的支持，而 LSXMS 使用 CPU 即可进行训练。模型训练需要能在普通配置的服务器中进行，更符合企业应用要求。

从业务来说，训练出的质量预测模型不仅要适应复杂多变的产品质量场景，还能对多工序制造特征进行分析，为产品工艺参数优化提供优化方向。LXSMS 模型能够提取出小样本特征的重要性，重要性高的特征蕴含着更高的业务影响能力；模型支持反馈训练及调整，能满足企业质量预测的需要。

综上所述，对于有限规模的制造数据集来说，采用何种模型需要结合业务目标来定，并综合考虑数据量、数据特征、训练成本和应用场景等问题。

3.7　实时产品质量预测应用设计

基于双星轮胎制造业务背景，设计了图 8 所示的服务框架，将 LXSMS 产品质量预测方法应用于实际的轮胎制造质量抽检预测。

对于历史质量检测与生产制造数据，直接使用 Logstash 工具将数据从不同系统中批量导入到 Elasticsearch 集群，方便对数据进行可视化质量分析、构建初始产品质量预测模型。

对生产的实时数据来说，由于 PLC 只包含终端设备的生产数据，轮胎描述和人员编号等信息需要从 MES 和 ERP 等系统抽取集成，而 Logstash 难以支持复杂的中间数据处理，因此使用 Kafka 分布式消息队列对所有数据进行集成，并将数据实时推送到 Elasticsearch 集群，为实时产品质量分析提供数据来源。由于涉及到数据的重复消费问题，故可以采用“发布-订阅”的消息传递模式，构建多个 consumer.group.id 来实现数据的多次消费。其中，待检验产品数据对应动平衡检验工序后所构建的待质量抽检预测数据。检验后产品数据对应均匀性检验工序后所构建的包含实际已检验的轮胎数据。最终所有数据都会归档到 Hadoop 中，用于构建产品质量预测模型，并导出为支持跨平台运行的 PMML 格式文件。该文件由质量预测模型管理服务负责管理，可以方便地被 Java 解析并完成实时轮胎质量预测任务。

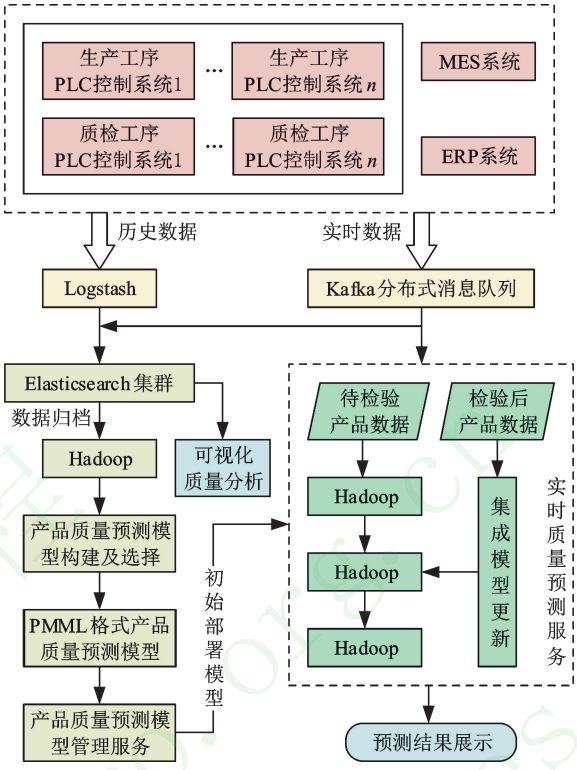


图 8　产品质量预测服务框架

Fig.8　Service framework of product quality prediction

4　结论

针对轮胎制造数据与轮胎检测数据的不平衡、轮胎均匀性检测中不合格品检出率的预测需求，提出了基于密度聚类与多工序制造特征的质检数据过采样 MCDC-MF-SMOTE 方法。与其他数据过采样方法相比，该方法的 A_{AUCPRC} 提高 5%～49%，有效地解决了合格与不合格的产品数量不平衡对不合格品抽出率预测的影响。为进一步提高产品质量预测方法的适应性，提出了基于 Stacking 集成的汽车零部件抽检不合格品预测 LXSMS 方法，利用 MCDC-MF-SMOTE 方法解决小样本检测数据类别不平衡问题，将 LightGBM、XGBoost、SVM 和 MNB 模型进行 Stacking 集成来预测抽检工序的不合格品。实验表明，该方法具有更高的稳定性和不合格品检出率的预测性能，相比于随机抽检，不合格产品检出率提高了

63%。

对于汽车零部件大批量生产、小样本抽检的不合格品检出预测问题，虽然本文所提出的LXSMS集成学习方法性能优异，但是集成学习算法一直存在着模型训练时间长的问题。未来需要针对制造业小样本不平衡的数据集，研究更高效的模型训练方法，以及更加实时稳定的模型应用策略。

参考文献：

[1] COSTA C F, NASCIMENTO M A. Ida 2016 Industrial Challenge: Using Machine Learning for Predicting Failures[C]// International Symposium on Intelligent Data Analysis. Cham, 2016: 381-386.

[2] LUO B, WANG H, LIU H, et al. Early Fault Detection of Machine Tools Based on Deep Learning and Dynamic Identification[J]. IEEE Transactions on Industrial Electronics, 2019, 66(1): 509-518.

[3] KROLL B, SCHAFFRANEK D, SCHRIEGEL S, et al. System Modeling Based on Machine Learning for Anomaly Detection and Predictive Maintenance in Industrial Plants[C]// 19th IEEE International Conference on Emerging Technologies and Factory Automation (ETFA). Barcelona, 2014: 1-7.

[4] KAUR H, PANNU H S, MALHI A K. A Systematic Review on Imbalanced Data Challenges in Machine Learning: Applications and Solutions[J]. ACM Computing Surveys (CSUR), 2019, 52(4): 1-36.

[5] KRAWCZYK B. Learning from Imbalanced Data: Open Challenges and Future Directions[J]. Progress in Artificial Intelligence, 2016, 5(4): 221-232.

[6] HAIXIANG G, YIJING L, SHANG J, et al. Learning from Class-imbalanced Data: Review of Methods and Applications[J]. Expert Systems with Applications, 2017, 73: 220-239.

[7] SHAHEE S A, ANANTHAKUMAR U. An Adaptive Oversampling Technique for Imbalanced Datasets[C]// Industrial Conference on Data Mining ICDM2018. New York, 2018: 1-16.

[8] KAUR P, GOSAIN A. FF-SMOTE: a Metaheuristic Approach to Combat Class Imbalance in Binary Classification[J]. Applied Artificial Intelligence, 2019, 33(5): 420-439.

[9] YAN Y, LIU R, DING Z, et al. A Parameter-free Cleaning Method for SMOTE in Imbalanced Classification[J]. IEEE Access, 2019, 7: 23537-23548.

[10] DOUZAS G, BACAO F. Self-Organizing Map Oversampling (SOMO) for Imbalanced Data Set Learning[J]. Expert Systems with Applications, 2017, 82:40-52.

[11] 朱海平，尹惠，邓宇浩，等.过程均值偏移随机的EWMA控制图优化设计[J]. 计算机集成制造系统，2014, 20(11): 2820-2825.
ZHU Haiping, YIN Hui, DENG Yuhao, et al. Optimization Design of EWMA Control Chart under Random Process Mean Shift[J]. Computer Integrated Manufacturing Systems, 2014, 20(11): 2820-2825.

[12] 吕旭泽.基于PSO-LS-SVM的发动机多工序装配质量预测模型研究[D].合肥：合肥工业大学，2016.
LYU Xuze. Research on the Engine Crankshaft Multistep Assembly Quality Prediction Model Based on LS-SVM of Particle Swarm Optimization [D]. Hefei: Hefei University of Technology, 2016.

[13] 赵双凤.基于MES的机加车间制造过程工序质量控制方法与系统研究[D]. 重庆：重庆大学, 2016
ZHA Shuangfeng. Research on Method and System of Process Quality Control for Machine Shop Manufacturing Process Based on MES [D]. Chongqing: Chongqing University, 2016.

[14] 于文靖.汽轮机模锻叶片加工质量预测及控制方法研究[D].哈尔滨：哈尔滨工业大学，2018.
YU Wenjing. Research on the Processing Quality Prediction Method of Turbing Die-forging Blade [D]. Harbin: Harbin Institute of Technology, 2018.

[15] 冯尔磊. 基于SMT大数据的产品质量预测方法研究与实现[D].西安：西安电子科技大学，2018.
Feng Erlei. Research on Analysis Method of SMT Product Quality Prediction Based on Big Data[D]. Xi'an: Xidian University, 2018.

[16] 杨岚. 基于大数据的多工序制造过程产品质量控制研究 [D]. 绵阳：西南科技大学，2020.
YANG Lan. Research On Product Quality Control Of Multistage Manufacturing Process Based On Big Data[D]. Mianyang: Southwest University of Science and Technology, 2020.

[17] MA L, FAN S. CURE-SMOTE Algorithm and Hybrid Algorithm for Feature Selection and Parameter Optimization Based on Random Forests [J]. BMC Bioinformatics, 2017, 18(1): 169.

（编辑 张 洋）

作者简介：李敏波，男，1970年生，副教授，博士。研究方向为工业大数据分析、物联网智能信息处理。发表论文40余篇。Email：limb@fudan.edu.cn。